LAPORAN PRAKTIKUM MACHINE LEARNING OPERATIONS (MLOps)

MODUL 6 : MODEL EXPERIMENTATION & TRACKING MENGGUNAKAN MLFLOW

Nama : Melinza Nabila

NIM : 123450122

I. PENDAHULUAN & TUJUAN

1.1 Latar Belakang

Pengembangan model machine learning bersifat eksploratif dan iteratif. Algoritma, hyperparameter, dan konfigurasi pelatihan terus diubah untuk mencari performa terbaik, sehingga setiap percobaan perlu terdokumentasi dengan baik. Tanpa pencatatan yang terstruktur, hasil eksperimen sulit dibandingkan, dan model yang dipilih untuk produksi tidak dapat ditelusuri kembali asal-usulnya maupun direproduksi (masalah *reproducibility*).

Experiment tracking menjawab masalah tersebut dengan mencatat konteks setiap *run*: parameter, metrik evaluasi, dan artefak model. MLflow adalah platform *open-source* yang banyak dipakai untuk mengelola siklus hidup eksperimen tersebut secara terpusat. Praktikum ini menerapkan MLflow pada studi kasus klasifikasi *Breast Cancer Wisconsin* menggunakan algoritma Random Forest, dengan membandingkan dua konfigurasi hyperparameter.

1.2 Tujuan Praktikum

- Mengimplementasikan *experiment tracking* menggunakan MLflow pada lingkungan Google Colab.
- Mencatat (*logging*) parameter, metrik evaluasi, dan artefak model dari setiap eksperimen.
- Membandingkan dua konfigurasi Random Forest (baseline dan tuning) berdasarkan hasil tracking.
- Menyimpan artefak tambahan berupa gambar hasil evaluasi ke dalam MLflow dan menangani kendala deserialisasi model pada MLflow 3 melalui `skops_trusted_types`.

II. METODOLOGI & SKENARIO EKSPERIMEN

2.1 Lingkungan Eksperimen

Komponen	Keterangan
Platform	Google Colab (Python 3.13)
Library utama	MLflow 3.17.0, Pandas, Scikit-learn, Matplotlib
Penyimpanan tracking	Backend database lokal yang dibuat otomatis oleh MLflow; artefak disimpan di `/content/mlruns/1`

2.2 Dataset dan Pembagian Data

Dataset yang digunakan adalah *Breast Cancer Wisconsin (Diagnostic)* dari `sklearn.datasets`, terdiri atas 569 sampel dengan 30 fitur numerik hasil pengukuran citra sel tumor. Label target bernilai 0 (*malignant*, 212 sampel) dan 1 (*benign*, 357 sampel). Data dibagi menjadi 80% data latih (455 sampel) dan 20% data uji (114 sampel) menggunakan `train_test_split` dengan `random_state=42`. Pembagian ini tidak menggunakan *stratify*; pada data uji terdapat 43 sampel malignant dan 71 sampel benign.

2.3 Skenario Eksperimen dan Hyperparameter

Run	Nama run	n_estimators	max_depth	random_state
1	RandomForest_baseline	100	5	42
2	RandomForest_tuning	200	10	42

2.4 Metrik Evaluasi

- **Accuracy**: proporsi prediksi yang benar dari seluruh data uji.
- **F1-Score**: rata-rata harmonik precision dan recall untuk kelas positif (label 1 = benign, sesuai pengaturan default dataset).
- `roc_auc_score` diimpor pada notebook, tetapi tidak dihitung maupun dicatat pada eksperimen ini.

III. IMPLEMENTASI KODE PROGRAM

Seluruh langkah dijalankan pada notebook `123450122_Melinza_Nabila_P6_MLOPS.ipynb`. Berikut ringkasan tiap tahap.

3.1 Instalasi dan Import Library

```
pip install mlflow

import mlflow
import mlflow.sklearn
import pandas as pd
from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, f1_score, roc_auc_score
```

3.2 Load Dataset dan Pembagian Data

```
data = load_breast_cancer()
X = data.data
y = data.target

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42)
```

3.3 Membuat Experiment MLflow

```
mlflow.set_experiment("Breast Cancer Classification")
```

3.4 Eksperimen 1: Model Baseline

```
params = {"n_estimators":100, "max_depth":5, "random_state":42}

with mlflow.start_run(run_name="RandomForest_baseline"):
    model = RandomForestClassifier(**params)
    model.fit(X_train, y_train)
    prediction = model.predict(X_test)

    accuracy = accuracy_score(y_test, prediction)
    f1 = f1_score(y_test, prediction)

    mlflow.log_params(params)
    mlflow.log_metric("accuracy", accuracy)
    mlflow.log_metric("f1_score", f1)
    mlflow.sklearn.log_model(
        model, "random_forest_model",
        skops_trusted_types=["sklearn.tree._tree.Tree"])
```

3.5 Eksperimen 2: Model Tuning

```
params = {"n_estimators":200, "max_depth":10, "random_state":42}

with mlflow.start_run(run_name="RandomForest_tuning"):
    model = RandomForestClassifier(**params)
    model.fit(X_train, y_train)
    prediction = model.predict(X_test)

    accuracy = accuracy_score(y_test, prediction)
    f1 = f1_score(y_test, prediction)

    mlflow.log_params(params)
    mlflow.log_metric("accuracy", accuracy)
    mlflow.log_metric("f1_score", f1)
    mlflow.sklearn.log_model(
        model, "random_forest_tuned",
        skops_trusted_types=["sklearn.tree._tree.Tree"])
```

3.6 Membandingkan Hasil dan Logging Artifact

```
runs = mlflow.search_runs()
runs[["run_id", "params.n_estimators", "params.max_depth",
      "metrics.accuracy", "metrics.f1_score"]]

import matplotlib.pyplot as plt
plt.plot(["accuracy"], [accuracy])
plt.savefig("accuracy_plot.png")
mlflow.log_artifact("accuracy_plot.png")
```

IV. HASIL EKSPERIMEN & ANALISIS TRACKING

4.1 Pembuatan Experiment

Saat `mlflow.set_experiment` dijalankan pertama kali, MLflow membuat tabel database awal dan experiment baru bernama **Breast Cancer Classification** dengan *experiment_id* = 1 serta lokasi artefak `/content/mlruns/1`.

4.2 Hasil Tracking (mlflow.search_runs)

run_id	n_estimators	max_depth	accuracy	f1_score
cf58209932cd4239b50ca590add9bae7	200	10	0.964912	0.972222
0805a40247934f57b0119aae2f009b8d	100	5	0.964912	0.972222

Tabel 1. Dua run yang tercatat pada experiment Breast Cancer Classification

4.3 Perbandingan Konfigurasi

Run	Model	n_estimators	max_depth	Accuracy	F1-Score
1	RandomForest baseline	100	5	0.964912 (96,49%)	0.972222 (97,22%)
2	RandomForest tuning	200	10	0.964912 (96,49%)	0.972222 (97,22%)

Tabel 2. Perbandingan metrik kedua konfigurasi pada data uji (114 sampel)

4.4 Artefak Hasil Evaluasi



Gambar 1. Artefak `accuracy_plot.png` *yang disimpan melalui* `mlflow.log_artifact`*. Plot hanya berisi satu titik tanpa marker sehingga tampak kosong.*

4.5 Analisis Tambahan: Confusion Matrix

Untuk melihat jenis kesalahan model, hasil prediksi dihitung ulang di luar MLflow dengan konfigurasi dan *random_state* yang sama. Nilai accuracy dan F1 yang diperoleh identik dengan hasil tracking di atas, dan kedua konfigurasi menghasilkan *confusion matrix* yang sama. Analisis ini tidak dicatat ke MLflow.

Aktual \ Prediksi	Malignant (0)	Benign (1)
Malignant (0)	40	3
Benign (1)	1	70

Tabel 3. Confusion matrix pada data uji (kedua konfigurasi)

Model melewatkan 3 dari 43 kasus malignant (recall malignant 93,02%) dan salah menandai 1 kasus benign sebagai malignant. Untuk kelas positif benign, precision bernilai 0,9589 dan recall 0,9859, yang konsisten dengan F1-Score 0,972222.

V. PEMBAHASAN

- **Performa kedua konfigurasi sama.** Menaikkan n_estimators dari 100 ke 200 dan max_depth dari 5 ke 10 tidak mengubah accuracy (0.964912) maupun F1-Score (0.972222). Dengan 114 data uji, satu sampel setara dengan sekitar 0,88 poin persentase, dan pada kedua model hanya 4 sampel yang salah klasifikasi, sehingga dataset ini tampaknya sudah cukup mudah dipisahkan oleh model baseline.
- **Manfaat tracking.** Setiap run menyimpan parameter, metrik, dan model dalam satu tempat, sehingga perbandingan dapat dilakukan lewat `search_runs` tanpa mencatat manual. Hasil di atas juga menunjukkan bahwa tuning tidak memberi keuntungan, sehingga model baseline yang lebih sederhana cukup dipertahankan.
- **Penanganan MLflow 3.** Pencatatan model scikit-learn pada MLflow 3 menggunakan serialisasi skops yang memerlukan daftar tipe tepercaya. Parameter

`skops_trusted_types=["sklearn.tree._tree.Tree"]` pada kedua run memungkinkan model Random Forest tersimpan.

- **Peringatan deprecation.** Log menampilkan peringatan bahwa `artifact_path` sudah usang. Penyebabnya, nama model diberikan sebagai argumen posisi; sebaiknya digunakan `name="..."`.
- **Run tambahan dari log_artifact.** Pemanggilan `mlflow.log_artifact` dilakukan di luar blok `with mlflow.start_run`. Karena tidak ada run aktif, MLflow membuat run baru secara otomatis untuk artefak tersebut. Run ini tidak muncul pada Tabel 1 karena `search_runs` dijalankan sebelumnya.

Keterbatasan dan saran pengembangan

- Hanya accuracy dan F1-Score yang dicatat. Pada konteks diagnosis, precision dan recall per kelas (terutama recall malignant) sebaiknya ikut dicatat ke MLflow.
- Pembagian data tidak menggunakan *stratify* dan evaluasi hanya satu kali pada satu *split*. Cross-validation atau beberapa nilai *random_state* akan memberi gambaran performa yang lebih stabil.
- Versi data belum dicatat. Menyimpan checksum data (misalnya MD5) sebagai tag akan memperkuat *data lineage*.
- Penyimpanan di `/content/mlruns` pada Colab bersifat sementara; untuk penggunaan berkelanjutan diperlukan MLflow Tracking Server dengan penyimpanan permanen.
- Plot accuracy sebaiknya diganti diagram batang yang membandingkan kedua run agar informatif.

VI. KESIMPULAN

1. MLflow berhasil digunakan untuk mencatat parameter, metrik, dan model dari dua eksperimen Random Forest pada dataset Breast Cancer dalam satu experiment terpusat.

2. Konfigurasi baseline (100 pohon, kedalaman 5) dan tuning (200 pohon, kedalaman 10) menghasilkan accuracy 0.964912 dan F1-Score 0.972222 yang identik, sehingga tuning tidak meningkatkan performa pada data ini.

3. Parameter `skops_trusted_types` diperlukan agar model scikit-learn dapat tersimpan pada MLflow 3, dan `search_runs` memudahkan perbandingan hasil secara sistematis.

4. Eksperimen berikutnya sebaiknya menambah metrik precision/recall, data versioning, dan validasi yang lebih kuat agar hasil lebih dapat diandalkan.